

Analiza czasu trwania – modele nieparametryczne

Aneta Ptak-Chmielewska

aptak@sgh.waw.pl

Wprowadzenie do modeli nieparametrycznych

- Modele analizy przeżycia można również podzielić na:
 - modele **pojedynczych** epizodów:
 - jeden stan wyjścia i jeden stan przeznaczenia,
 - jeden stan wyjścia i alternatywne stany przeznaczenia (modele ryzyka konkurencyjnego),
 - modele **wielu** epizodów – wiele stanów wyjścia i wiele stanów kończących.

Przedstawione klasyfikacje modeli nie są rozłączne.

Dla modeli pojedynczych epizodów czas jest wyznaczany od momentu zajścia zdarzenia początkowego (stan wyjścia) do momentu zajścia zdarzenia, które eliminuje obserwowaną jednostkę z określonej zbiorowości (stan przeznaczenia).

Tak zdefiniowany czas oczekiwania na wystąpienie zdarzenia stanowi podstawę modelowania w analizie przeżycia.

Modele nieparametryczne - zastosowanie

- Wstępna analiza danych – opisowa
- Statystyki opisowe np. mediana do modeli parametrycznych
- Dopasowanie modeli parametrycznych
- Proste eksperymenty – porównanie funkcji przeżycia
- W demografii do analizy procesu umieralności ludności

Wprowadzenie do modeli nieparametrycznych

Modele nieparametryczne:

- są najczęściej wykorzystywane we wstępnej analizie badanych procesów,
- są stosowane wtedy, gdy przedmiot zainteresowania badacza stanowi kształt funkcji przeżycia, funkcji gęstości czy funkcji hazardu,
- to modele, dla których nie jest określona (znana) analityczna postać zmiennej losowej opisującej czas trwania (przeżycia).

Modele nieparametryczne służą do opisu procesu przeżycia i ubywania jednostek z pewnej ściśle określonej zbiorowości na skutek zajścia określonego zdarzenia.

Wprowadzenie do modeli nieparametrycznych

- Najstarszym przykładem modeli nieparametrycznych są tablice trwania życia.
- Pierwsze tablice trwania życia pochodzą z XVII w., opublikował je John Graunt w 1662 r. i dotyczyły one procesu wymieralności mieszkańców Londynu.
- Dla Polski pierwsze tablice trwania życia zostały opublikowane przez J. Słonimskiego i A. B. Danielewicza w XIX w. i dotyczyły długości życia mieszkańców Warszawy.
- Początek rozwoju współczesnych nieparametrycznych metod analizy przeżycia związany jest z publikacją E.L. Kaplana i P. Meiera [1958], w której przedstawiono nową metodę estymacji krzywej przeżycia.

Wprowadzenie do modeli nieparametrycznych

Klasyfikacje tablic trwania życia:

- surowe (empiryczne) i modelowe (wyrównane, hipotetyczne),
- pełne i skrócone,
- tablice kohortowe i przekrojowe.

Tablice surowe – prezentowane w nich wartości są wyznaczane na podstawie „surowych” danych empirycznych.

Tablice modelowe (wyrównane, hipotetyczne) – prezentowane w nich wartości są wyznaczone przy przyjęciu określonych założeń teoretycznych potrzebnych do ich wyznaczenia (np. wykorzystywane są rozkłady teoretyczne zamiast empirycznych).

Tablice pełne – tablice trwania życia (wymieralności), w których rozważane przedziały czasu wynoszą jeden rok.

Tablice skrócone – tablice trwania życia (wymieralności), w których rozważa się dłuższe niż jeden rok przedziały czasu, najczęściej pięcioletnie.

Ostatni podział na kohortowe i przekrojowe jest najczęściej wykorzystywany w demografii.

Wprowadzenie do modeli nieparametrycznych

Tablice kohortowe i przekrojowe.

Kohorta – grupa ludzi lub obiektów wyodrębniona z populacji na podstawie określonego wydarzenia (zdarzenia), które zaszło jednocześnie dla całej tej grupy w ściśle określonym miejscu i czasie. W przypadku, gdy tym zdarzeniem jest urodzenie, to taką kohortę nazywa się kohortą urodzeniową (birth cohort).

Badania przeprowadzane z wykorzystaniem kohorty zwane są badaniami kohortowymi.

Tablice **kohortowe** – zawierają wyniki z obserwacji kohorty od momentu jej powstania, przez długi czas, aż do momentu opuszczenia kohorty przez wszystkie jednostki bądź też do momentu zakończenia obserwacji.

Tablice **przekrojowe** – zawierają wyniki z obserwacji jednostek z różnych generacji w krótkim okresie

Modele nieparametryczne – rodzaje

- **Metoda Kaplana-Meiera** (*Kaplan-Meier method*)
 - dokładny pomiar czasu
 - mała liczba obserwacji i zdarzeń
 - Znana jako PLE *product-limit estimator*
 - Estymator **Nelsona-Aalena** do szacowania skumulowanej funkcji hazardu
- **Metoda tradycyjna** tzw. **aktuarialna** (*life table or actuarial method*)
 - duże zbiory danych
 - liczne zdarzenia

PROC LIFETEST

- Oszacowanie funkcji przeżycia i wykresów funkcji przeżycia
 - metodą Kaplana-Meiera (PLE)
 - metodą tradycyjną
- Testowanie hipotezy o równości funkcji przeżycia w podgrupach (strata)
- Testowanie zależności pomiędzy czasem przeżycia a zmiennymi ilościowymi

Estymator Kaplana-Meiera funkcji przeżycia

$$\hat{S}(t) = \prod_{j:t_j \leq t} \left(1 - \frac{d_j}{n_j}\right) \text{ dla } t_1 \leq t \leq t_k$$

$t_1 < t_2 < \dots < t_k$ - k różnych czasów zdarzeń

n_j - liczba jednostek wystawionych na ryzyko w momencie t_j

d_j - liczba jednostek które doświadczyły zdarzenia w czasie t_j

Funkcja $S(t)$ zaczyna się w 1,0 i zbiega do 0 jeśli nie ma obserwacji obciętych lub do największej wartości nieobciętej jeśli występują.

Estymator Kaplana-Meiera skumulowanej funkcji hazardu

Metoda Kaplana-Meiera umożliwia również estymację skumulowanej funkcji hazardu:

$$H_j = -\ln(S_j)$$

Standardowy błąd estymacji:

$$D(H_j) = \sqrt{\sum_{k=1}^j \frac{d_k}{n_k(n_k - d_k)}}$$

Estymacja skumulowanej funkcji hazardu metodą Nelsona-Aalena

- Skumulowana funkcja hazardu dana jest wzorem:

$$H(t) = \int_0^t h(u) du, \text{ dla } t \geq 0$$

- Estymację skumulowanej funkcji hazardu metodą Nelsona-Aalena przeprowadza się dla **małych prób**.
- Nieparametryczny estymator tej funkcji ma postać:

$$H_j = \sum_{k=1}^j \frac{d_k}{n_k}$$

d_k – liczba zdarzeń, n_k – liczba jednostek wystawionych na ryzyko zdarzenia

Przykład 1. *myelomatosis data*

- Kod 1: Oszacowanie funkcji przeżycia, porażkę (1-przeżycie), błąd std (formuła Greenwooda), liczba pozostałych, liczba zdarzeń, kwartyle, srednia. PLE jest opcją domyślną.
- Kod 2: PLE wykres funkcji przeżycia z oznaczenia obs obciętych.
- Kod 3: wykres bez oznaczenia obserwacji obciętych, z przedziałami ufności i liczbą obserwacji wystawionych na ryzyko. CL czyli *pointwise limits* oraz opcja CB (*confidence bonds*) w wersji EP (*equal precision*).

* CB są zawsze szersze niż CL ponieważ mówią o 95% prawdopodobieństwie zawarcia się prawdopodobieństwa przeżycia natomiast CL mówią o 95% prawdopodobieństwie zawarcia się funkcji przeżycia w danym przedziale.

Przykład 1 – przedziały ufności $S(t)$

- Kod 4: oszacowanie przedziałów ufności dla każdej jednostki czasu,
- ALPHA=0.10 – możliwość oszacowania przedziałów 90%.
- CL wyznaczone są przez +/- 1.99 do domyślnej transformacji dla funkcji przeżycia: $\log(-\log\hat{S}(t))$, po odwróceniu otrzymujemy CL.
- Inna transformacja: $\log[\hat{S}(t)/(1 - \hat{S}(t))]$ w opcji CONFTYPE=LOGIT.
- Dla EP *confidence bonds* opcja CONFBAND=EP.

Testy różnic funkcji przeżycia między grupami

$$H_0: S_1(t) = S_2(t)$$

dla wszystkich t czyli brak jest różnic pomiędzy funkcjami przeżycia dla tych grup

$$H_1: S_1(t) \neq S_2(t)$$

czyli występują istotne różnice między grupami.

Test może być rozszerzony na więcej grup. Opcja STRATA w PROC LIFETEST.

Testy różnic funkcji przeżycia między grupami

Statystyka testowa (r - liczba punktów czasu):

$$\sum_{j=1}^r w_j (d_{1j} - e_{1j})$$

d_{1j} – liczba zdarzeń które wystąpiły w grupie 1 w czasie j .

$e_{1j} = n_{1j}d_j/n_j$ oczekiwana liczba zdarzeń w grupie 1 w czasie j .

n_j – ogólna liczba obserwacji wystawionych na ryzyko przed czasem j .

n_{1j} – liczba wystawionych na ryzyko przed czasem j w grupie 1.

d_j – liczba zdarzeń w czasie j w obu grupach.

Statystyka chi-kwadrat jest kwadratem statystyki testowej dzielonym przez wariancję.

Testy - formuła

- *Test log-rang (log-rank)*
- *Test Wilcoxona*
- *Test Tarone-Ware*
- *Test Peto-Peto*
- *Test Fleming-Harrington*

- $\sum_{j=1}^r (d_{1j} - e_{1j})$
- $\sum_{j=1}^r n_j (d_{1j} - e_{1j})$
- $\sum_{j=1}^r \sqrt{n_j} (d_{1j} - e_{1j})$
- $\sum_{j=1}^r \hat{S}(t_j) (d_{1j} - e_{1j})$
- $\sum_{j=1}^r \hat{S}(t_j)^p (1 - \hat{S}(t_j))^q$

Testy - porównanie

- *Test log-rang (log-rank)*
 - *Test Wilcoxona*
 - *Test Tarone-Ware*
 - *Test Peto-Peto*
 - *Test Fleming-Harrington*
- Podstawowy test, dobrze sprawdza się przy równoległych funkcjach przeżycia
 - Większa waga dla początkowego czasu niż dla końcowego, mniej wrażliwy niż log-rang na różnice w funkcja przeżycia w końcowym przebiegu.
 - Podobnie jak Wilcoxon.
 - Mniej wrażliwy na różnice w rozkładzie obserwacji obciętych.
 - Uogólnienie testów w zależności od użytych parametrów p i q .

Przykład 2. test na równość funkcji przeżycia

- Kod 5. test na różnice w przebiegu funkcji przeżycia między dwoma grupami, statystyka log-rang i Wilcoxon, statystyka chi-kwadrat i p-value. Zbiór *myelomatosis data*.
- Kod 6. test na różnice w przebiegu funkcji przeżycia między grupami dla zbioru *recidivism data* (recid). Porównanie parami (ADJUST=TUKEY/BON)
 - WEEK – tydzień aresztowania po zwolnieniu
 - ARREST – 1 aresztowany w ciągu roku po zwolnieniu, 0 nie był aresztowany (censored)
 - FIN – 1 pomoc finansowa, 0 brak pomocy
 - AGE – wiek w momencie zwolnienia
 - RACE – rasa 1- czarny, 0 -inne
 - WEXP – 1 pracował przed, 0 inne
 - MAR – 1 żonaty w momencie zwolnienia, 0 – nie
 - PARO – 1 zwolnienie warunkowe, 0- inne
 - PRIO – liczba wykroczeń przed aresztowaniem.

Tradycyjne tablice trwania życia

- Wymagają dużych liczebnie zbiorów danych.
- Wymagają podziału czasu na odcinki. Arbitralna decyzja.
- Dodatkowo dostarczają oszacowań i wykresów funkcji hazardu.
- Testy różnic funkcji przeżycia są wykonywane na danych niezagregowanych.
- Obserwacje obcięte wchodzą do przedziału czasu na środek przedziału. Wchodzą jako $\frac{1}{2}$ do liczności przedziału.

Tradycyjne tablice trwania życia

- Oznaczenia

- j – przedział
- t_{im} – środek przedziału
- b_j – rozpiętość przedziału
- d_j – liczba zdarzeń w przedziale
- N_j - oznacza liczbę jednostek, dla których nie zaszło zdarzenie do momentu, który jest ustalony jako początek j-tego przedziału
- n_j – liczba obserwacji wystawionych na ryzyko na początku przedziału
- m_j – liczba obserwacji obciętych wewnątrz przedziału

$$n_j = N_j - \frac{m_j}{2}$$

Tradycyjne tablice trwania życia

- Prawdopodobieństwo zajścia zdarzenia w j-tym przedziale

$$q_j = \frac{d_j}{n_j}$$

- Standardowy błąd oceny prawdopodobieństwa

$$D(q_j) = \sqrt{\frac{q_j p_j}{n_j}}$$

- Warunkowe prawdopodobieństwo przeżycia czasu dłuższego niż j-ty przedział

$$p_j = 1 - q_j = \frac{n_j - d_j}{n_j}$$

Tradycyjne tablice - funkcje

- Funkcja przeżycia dla j-tego przedziału

$$\hat{S}(t) = \prod_{k=0}^{j-1} p_k = \prod_{k=0}^{j-1} \left(\frac{n_k - d_k}{n_k} \right)$$

- Funkcja hazardu dla j-tego przedziału

$$h(t_{im}) = \frac{d_j}{b_j \left(n_j - \frac{w_j}{2} - \frac{d_j}{2} \right)}$$

Tradycyjne tablice trwania życia - przykład

- Dla 1000 obserwacji, w tym 600 zdarzeń

Dolny koniec przedziału	Górny koniec przedziału	Liczba zdarzeń d_j	Liczba obciętych m_j	Warunkowe prawd. zdarzenia	Błąd std.	Funkcja przeżycia	Dystrybucja
0	10	200	150	0,216	0,0135	1	0
10	20	150	100	0,250	0,0177	0,784	0,216
20	30	100	50				
30	40	100	50				
40	50	50	50				

Liczba jednostek dla których nie zaszło zdarzenie do momentu, który jest ustalony jako początek pierwszego przedziału: $N_0=N=1000$

Liczba jednostek dla których nie zaszło zdarzenie do momentu, który jest ustalony jako początek drugiego przedziału: $N_1=N_0-d_0-m_0=1000-200-150=650$

Tradycyjne tablice trwania życia - przykład

Liczba jednostek dla których nie zaszło zdarzenie do momentu, który jest ustalony jako początek trzeciego przedziału: $N_2 = N_1 - d_1 - m_1 = 650 - 150 - 100 = 400$ itd.

Liczba jednostek wystawionych na ryzyko zajścia zdarzenia w pierwszym przedziale (część opuściła – Ocenzurowanie): $n_0 = N_0 - m_0 / 2 = 1000 - 150 / 2 = 925$.

Liczba jednostek wystawiona na ryzyko zajścia zdarzenia w drugim przedziale:

$$n_1 = N_1 - m_1 / 2 = 650 - 100 / 2 = 600 \text{ itd.}$$

Warunkowe prawdopodobieństwo zajścia zdarzenia w pierwszym przedziale q_0 :

$$d_0 / n_0 = 200 / 925 = 0,216$$

Warunkowe prawdopodobieństwo zajścia zdarzenia w drugim przedziale q_1 :

$$d_1 / n_1 = 150 / 600 = 0,250. \text{ itd.}$$

Przykład 3. *recidivism data*

- Kod 7. Oszacowanie tradycyjnych tablic trwania życia METHOD=LIFE przy domyślnych odcinkach czasu.
- Inny sposób definicji odcinków czasu: WIDTH=w albo INTERVALS=a b c ..., odcinki czasu nie muszą być stałej długości.
- Kod 8. Wykres funkcji przeżycia i hazardu PLOTS=(S,H).
- Kod 9. Korekta ostatniego przedziału, domknięcie ostatniego przedziału na 53 tygodniu, zmiana censoring na 53 zamiast 52 co bardziej poprawnie ujmuje czas obcięcia (jako połowę przedziału).

Przykład 4. Tablice dla danych zagregowanych

- Kod 10. Estymacja tablic z danych zagregowanych zawierających: przedziały czasy, liczbę zdarzeń w każdym przedziale, liczbę obserwacji obciętych w każdym przedziale).
- Dane z programu przeszczepów. Dane z tablicy zakodowane w formie danych jednostkowych z dodatkową informacją o liczbie wystąpień NUMBER.
- Opcja FREQ numer uwzględnia liczebność.

Test na efekty zmiennych niezależnych

- Test zależności zmiennych ilościowych od zmiennej zależnej czas przeżycia.
- Test dla jednej zmiennej niezależnie od pozostałych lub na łączną niezależność wszystkich zmiennych od czasu przeżycia.
- Uogólnienie testu log-rang i testu Wilcoxona.
- Nieparametryczne testy współczynników modelu parametrycznego tzw. *accelerated failure time model*.
- Może służyć do preselekcji zmiennych wykorzystywanych później w modelach parametrycznych.
- STRATA i TEST różnią się ze względu na obserwacje powiązane (*ties*).

Przykład 5.

- Kod 11. Test na istotność korelacji zmiennych dla danych *recidivism data*. Znak testu wskazuje na kierunek zależności między zmienną a czasem przeżycia. Test Forward Stepwise Sequence – kolejność zmiennych.
- Kod 12. Uwzględnienie różnicy między TEST a STRATA na danych *myelomatosis*. Opcja GROUP w STRATA.
- STRATA TEST – brak zmian
- TEST STRATA – statystyki testowe są uśredniane według STRATA
- GROUP – zmienna grupująca może mieć więcej niż 2 kategorie w przeciwieństwie do TEST

Logarytm funkcji przeżycia

- Log survival plot (LS) $-\log\hat{S}(t)$ versus t
- Log log survival plot (LLS) $\log[-\log\hat{S}(t)]$ versus $\log t$
- Wykorzystywany do sprawdzenia kształtu funkcji hazardu. Kształt funkcji determinuje postać modelu parametrycznego.
- PROC LIFETEST opcja PLOTS=(S, LS, LLS).
- $-\log\hat{S}(t) = \int_0^t h(u)du$ czyli funkcja skumulowanego hazardu (tzw. *cumulative hazard function*).
- LS prosta od pkt 0 oznacza stały hazard w czasie czyli spełnienie założenia do modelu wykładniczego.
- LLS prosta od pkt 0 z nachyleniem β sugeruje model Weibulla z funkcją hazardu $\log h(t) = \alpha + \beta \log t$.

Wygładzanie kernela wykresu funkcji hazardu

- Wygładzenie funkcji hazardu do oceny jej kształtu (*kernel smoothing*).
- Opcja PLOTS=H w PROC LIFETEST.
- Opcja PLOT=H (BW=...) zmienia odcinek czasu wykorzystywany do wygładzania.
- Opcja PLOTS=H (CL) dodatkowo oznacza przedziały ufności.

Przykład 6.

- Kod 13. Wygładzanie funkcji z wykorzystaniem metody kernela.
- Kod 14. Dodatkowo zmiana zakresu BW i dodanie CL.