

Analiza czasu trwania – modele parametryczne

Aneta Ptak-Chmielewska

aptak@sgh.waw.pl

Parametryczne vs Semi-parametryczne

PROC LIFEREG

- Uwzględnia obcięcie lewostronne i przedziałowe
- Umożliwia testowanie kształtu funkcji hazardu.
- Bardziej efektywne estymatory (mniejsze błędy std).
- Łatwe oszacowanie przewidywanych czasów trwania dla specyficznych zmiennych.
- Nie uwzględnia zmiennych zależnych od czasu.

PROC PHREG

- Uwzględnia tylko prawostronne obcięcie
- Tylko nieparametryczne oszacowanie funkcji przeżycia, trudno interpretowalne.
- Mniej efektywne estymatory.
- Trudności w oszacowaniu precyzyjnym czasów trwania dla niektórych zmiennych, czasem niemożliwe.
- Umożliwia włączenie zmiennych zależnych od czasu.

Parametryczne modele

W analizie przeżycia **zmienną zależną jest czas trwania** do wystąpienia określonego zdarzenia.

W przypadku, gdy znany jest rozkład prawdopodobieństwa tej zmiennej, to rozważa się **parametryczne modele przeżycia**. Wówczas do opisu rozkładu prawdopodobieństwa **zależnej zmiennej losowej opisującej czas trwania** do wystąpienia określonego zdarzenia wykorzystuje się funkcje:

- gęstości,
- przeżycia,
- hazardu.

Wystarczy znajomość jednej z tych funkcji, gdyż na podstawie występujących zależności pomiędzy nimi można wyznaczyć pozostałe funkcje.

Graficzny kształt funkcji hazardu dla procesów trwania może przybierać w modelach parametrycznych różne formy. Można wyróżnić następujące funkcje hazardu:

- monotonicznie rosnące dla procesów, których zakończenie staje się coraz bardziej prawdopodobne im dłużej one trwają;
- monotonicznie malejące dla procesów, których zakończenie wraz z upływem czasu staje się coraz mniej prawdopodobne;
- o kształcie litery U lub odwróconej litery U;
- stałe w przypadku procesów, dla których nie istnieje żaden związek pomiędzy czasem ich trwania a ich zakończeniem.

Parametryczne modele przeżycia

W naukach społeczno-ekonomicznych najczęściej wykorzystywane są następujące rozkłady prawdopodobieństwa:

- rozkład wykładniczy
- rozkład Weibulla
- rozkład Gompertza
- rozkład gamma
- uogólnienia rozkładu gamma
- rozkład log-logistyczny
- rozkład logarytmiczno-normalny

Parametryczne modele przeżycia - podział

Wśród parametrycznych modeli przeżycia wyróżnia się dwie podstawowe klasy tych modeli:

- **modele proporcjonalnych hazardów** (proportional hazards models - PH),
- **modele przyspieszonej porażki** (accelerated failure time models - AFT, Log-Location-Scale)

Modele budowane z wykorzystaniem rozkładów:

- wykładniczego, Weibulla oraz Gompertza można rozważać jako **modele proporcjonalnych hazardów**;
- gamma, log-logistycznego, logarytmiczno-normalnego należą do klasy **modeli przyspieszonej porażki**.

Model wykładniczy oraz model Weibulla mogą być rozważane zarówno jako modele proporcjonalnych hazardów, jak i modele przyspieszonej porażki.

Modele proporcjonalnych hazardów

Modele **proporcjonalnych hazardów** to klasa modeli regresji, w których zależność funkcji hazardu od zmiennych objaśniających ma charakter multiplikatywny czy też proporcjonalny.

W modelu proporcjonalnych hazardów funkcja hazardu dla j -tej jednostki dana jest wzorem:

$$h(t|\mathbf{x}_j) = h_0(t) \exp(\boldsymbol{\beta}\mathbf{x}_j),$$

a dla i -tej:

$$h(t|\mathbf{x}_i) = h_0(t) \exp(\boldsymbol{\beta}\mathbf{x}_i).$$

Stąd relacja hazardu dla dwóch jednostek jest następująca:

$$HR(t, \mathbf{x}_i, \mathbf{x}_j) = \frac{h_0(t) \exp(\boldsymbol{\beta}\mathbf{x}_i)}{h_0(t) \exp(\boldsymbol{\beta}\mathbf{x}_j)} = \exp[\boldsymbol{\beta}(\mathbf{x}_i - \mathbf{x}_j)].$$

Modele proporcjonalnych hazardów

W praktyce stwierdzenie „proporcjonalnych hazardów” wiąże się z faktem, że funkcje hazardu są powiązane multiplikatywnie, czyli ich iloraz jest stały, przy założeniu, że x_i oraz x_j nie zmieniają się w czasie.

Założenie proporcjonalnego hazardu oznacza, że dla dwóch osób o określonych wartościach zmiennych objaśniających stosunek estymowanych wartości hazardu ma być **stały w czasie**.

Podsumowując, modele **proporcjonalnych hazardów** znajdują zastosowanie, gdy spełnione jest **założenie proporcjonalnych hazardów dotyczące stałości w czasie stosunku funkcji hazardów dla dwóch dowolnych jednostek**.

Modele proporcjonalnych hazardów

Wykorzystując odpowiednią parametryzację dla funkcji hazardu bazowego we wzorze:

$$h(t|\mathbf{x}) = h_0(t) \exp(\boldsymbol{\beta}\mathbf{x}),$$

można otrzymać wzory na funkcję hazardu dla danego rozkładu.

W wykładniczym modelu proporcjonalnych hazardów hazard bazowy nie zmienia się w czasie:

$$h_0(t) = \lambda.$$

Wówczas wzór na funkcję hazardu dla wykładniczego modelu proporcjonalnych hazardów ma postać:

$$h(t, \mathbf{x}) = \lambda \exp(\boldsymbol{\beta}\mathbf{x}).$$

Modele proporcjonalnych hazardów

Przyjmując dla funkcji hazardu bazowego następującą postać:

$$h_0(t) = \gamma^\alpha \alpha t^{\alpha-1}$$

otrzymujemy **model proporcjonalnych hazardów Weibulla**. Wzór na funkcję hazardu ma postać:

$$h(t, \mathbf{x}) = \gamma^\alpha (\gamma t)^\alpha \exp(\boldsymbol{\beta} \mathbf{x}).$$

Estymacja parametrów modeli parametrycznych w podejściu klasycznym przeprowadzana jest z wykorzystaniem metody największej wiarygodności MNW.

Modele przyspieszonej porażki

Drugą grupę modeli parametrycznych stanowią **modele przyspieszonej porażki** (*accelerated failure time models* - AFT)

W przypadku modeli przyspieszonej porażki efekt zmiennych objaśniających jest proporcjonalny w odniesieniu do czasu trwania, podczas gdy modelach proporcjonalnych hazardów efekt zmiennych objaśniających jest proporcjonalny w odniesieniu do hazardu.

Modele przyspieszonej porażki nazywane są również **modelami z przeskalowanym czasem życia**. Ma to związek z intuicyjnym rozumieniem tej klasy modeli, uwzględniającym to, że czas może „biec różnie”, zależnie od obserwacji, co wymaga odpowiedniego skalowania czasu.

Parametryczne modele przyspieszonej porażki dają możliwość opisanie zależności między funkcjami przeżycia opisującymi czas trwania dla dwóch grup jednostek.

Parametry modeli przyspieszonej porażki w podejściu klasycznym szacowane są **metodą największej wiarygodności**.

AFT Accelerated Failure Time Model

AFT to relacja między funkcją przeżycia dla dwóch różnych jednostek:

- $S_j(t) = S_i(\phi_{ij}t)$ dla wszystkich t
- gdzie ϕ_{ij} jest stałą specyficzną dla pary jednostek i, j czyli różnica między jednostkami to proporcja wieku w którym są te jednostki.

Model:

- $\log T_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \sigma \varepsilon_i$ lub po przekształceniu $\exp$
- $T_i = \exp(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \sigma \varepsilon_i)$
- gdzie T_i jest zmienna czas dla jednostki i , a $x_{i1}, \dots, x_{ik}$ to wartości zmiennych dla jednostki i .

Założenia i estymacja, weryfikacja

- Stała wartość oczekiwana i wariancja w rozkładzie zmiennej T .
- Niezależność pomiędzy obserwacjami.
- Parametry modeli w podejściu klasycznym szacowane są metodą największej wiarygodności ML – *maximum likelihood*, metoda największej wiarygodności.
- Kryteria informacyjne (im mniejsze tym lepsze dopasowanie modelu):
 - Log-likelihood: $-2 \log L$
 - Akaike information criterion $AIC = -2\log L + 2k$ (k-liczba zmiennych)
 - Skorygowany AIC: $AICC = AIC + \frac{2k(k+1)}{n-k-1}$ (n – liczebność próby)
 - Bayesian information criterion: $BIC = -2\log L + k \log n$

ML Maximum Likelihood Estimation (MNL)

- MNL – Metoda Największej Wiarygodności
- Przy dużej próbie, estymatory uzyskane MNL są:
 - Zgodne, dla dużych prób zbiegają do parametru
 - Nieobciążone,
 - Asymptotycznie efektywne, czyli mają najmniejszą wariancję spośród wszystkich estymatorów.
- Dodatkowo mają rozkład normalny czyli można wykorzystywać rozkład chi-kwadrat do przedziałów ufności i testów istotności.
- Dla małych prób, ostrożnie! NONCONVERGENCE!
- Procedura wymaga konstrukcji funkcji wiarygodności i jej maksymalizacji.

MNW - formuły

- Funkcja wiarygodności:
- $L = \prod_{i=1}^n f_i(t_i)$,
- Uwzględniając obciążenie:
- $L = \prod_{i=1}^r f_i(t_i) \prod_{i=r+1}^n S_i(t_i)$,
- $L = \prod_{i=1}^n [f_i(t_i)]^{\delta_i} [S_i(t_i)]^{1-\delta_i}$,
- Dla ułatwienia wykorzystuje się LL czyli log-likelihood do maksymalizacji.
- n – liczba niezależnych jednostek ($i=1, \dots, n$),
- t_i – czas zdarzenia lub obciążenia,
- δ_i – obciążenie (1-zdarzenie, 0-obciążenie),
- $\mathbf{x}_i$ – wektor wartości zmiennych dla jednostki (stałe zmienne).
- obciążenie nie-informacyjne.
- $f(t_i)$ – funkcja gęstości.

MNW – Algorytm Newtona-Raphsona

- Do optymalizacji czyli maksymalizacji LL czyli wyznaczenia estymatorów wykorzystuje się algorytmy numerycznych przybliżeń.
- LIFEREG wykorzystuje brzegowo stabilny algorytm Newtona-Raphsona.
- $\mathbf{U}(\boldsymbol{\beta}) = \frac{\partial \log L}{\partial \boldsymbol{\beta}} = -\sum_{i=1}^n \delta_i \mathbf{x}_i + \sum_{i=1}^n t_i \exp(-\boldsymbol{\beta} \mathbf{x}_i) \mathbf{x}_i$ - wektor pierwszych pochodnych $\log L$ po $\boldsymbol{\beta}$. (*gradient* lub *score*)
- $\mathbf{I}(\boldsymbol{\beta}) = \frac{\partial^2 \log L}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} = -\sum_{i=1}^n t_i \exp(-\boldsymbol{\beta} \mathbf{x}_i) \mathbf{x}_i \mathbf{x}_i'$ - macierz drugich pochodnych po $\boldsymbol{\beta}$. (*Hessian*)
- $\boldsymbol{\beta}_{j+1} = \boldsymbol{\beta}_j - \mathbf{I}^{-1}(\boldsymbol{\beta}_j) \mathbf{U}(\boldsymbol{\beta}_j)$

Przykład 1. *recidivism data*

- KOD 1: PROC LIFEREG – oszacowanie modelu ze zmiennymi. Rozkład zmiennej zależnej *czas* dany jest rozkładem log-normalnym.
- Dla zmiennych binarnych interpretacja: $\exp(\beta)$ różnica (%) między oczekiwanym czasem dla dwóch grup 1 vs 0.
- Dla zmiennych ciągłych: $100[\exp(\beta)-1]$ procentowa zmiana oczekiwanego czasu przeżycia dla jednostkowej zmiany zmiennej X.
- SCALE= σ kształt funkcji hazardu.

Modele parametryczne PROC LIFEREG

Rozkład reszt ε

- Wartości ekstremalnych (2 parametry) - *extreme value*
- Wartości ekstremalnych (1 parametr) - *extreme value*
- *Log-gamma*
- *Logistic*
- *Normal*

Rozkład zmiennej T

- Weibull (Weibulla)
- Exponential (wykładniczy)
- Gamma
- Log-logistic (logarytmiczno-logistyczny)
- Log-normal (logarytmiczno-normalny)

Model wykładniczy (D=EXPONENTIAL)


- $\log h(t) = \dot{\beta}_0 + \dot{\beta}_1 x_1 + \dots + \dot{\beta}_k x_k$ gdzie $\beta_j = -\dot{\beta}_j$
- czyli im wyższy hazard tym krótszy czas
- brak składnika losowego – zmienność losowa jest zawarta w zależności między nieobserwowalnym hazardem a obserwowalnym czasem.
- wskaźnik hazardu stały w czasie.

Przykład 2. *recidivism data* D=EXPONENTIAL

- KOD 1 – z opcją DISTRIBUTION=EXPONENTIAL
- SCALE=1.0 – „Lagrange Multiplier Statistics” weryfikuje czy faktycznie $\sigma = 1$.
- Hipoteza zerowa jest odrzucona czyli hazard nie jest stały w czasie.

Model Weibulla (D=WEIBULL)

- Rozszerzenie modelu wykładniczego, dopuszcza hazard niestały w czasie:
 - $\sigma > 1$ – hazard malejący w czasie,
 - $0,5 < \sigma < 1$ – rosnący z malejącym trendem,
 - $0 < \sigma < 0,5$ – rosnący z rosnącym trendem,
 - $\sigma = 0,5$ – prosty rosnący.




- Model Weibulla oprócz AFT jest również modelem proporcjonalnego hazardu (log-hazard lub log-survival).
- $\log h(t) = \alpha \log t + \dot{\beta}_0 + \dot{\beta}_1 x_1 + \dots + \dot{\beta}_k x_k$ gdzie $\alpha = (1/\sigma) - 1$
- $\log T_i = \dot{\beta}_0 + \dot{\beta}_1 x_1 + \dots + \dot{\beta}_k x_k + \sigma \varepsilon$ gdzie $\dot{\beta}_j = -\frac{\beta}{\sigma}$ dla $j = 1, \dots, k$

Przykład 3. *recidivism data* D=WEIBULL

- KOD 1 – z opcją DISTRIBUTION=WEIBULL.
- Weibull Shape= $1/\hat{\sigma}$ czyli 1/SCALE.
- $\hat{\alpha} = \left(\frac{1}{0,7124} \right) - 1 = 0,4037$ czyli współczynnik *log t* w modelu log-hazard, 1% wzrost czasu jest związany z 0,4% spadku w ryzyku (hazard) aresztowania.


Model Logarytmiczno-normalny (D=LNORMAL)

- Niemonotoniczna funkcja hazardu:
- $\log h(t) = \log h_0(te^{-\beta x}) - \beta x$ gdzie $h_0(.)$ jest funkcją hazardu dla jednostki z $\mathbf{x}=0$.
- Patrz Przykład 1.



Model Logarytmiczno-logistyczny (D=LLOGISTIC)

- Model zakłada logistyczny rozkład składnika losowego ε .
- Stąd rozkład T jest rozkładem log-logistycznym:
- $h(t) = \frac{\lambda \gamma (\lambda t)^{\gamma-1}}{1 + (\lambda t)^\gamma}$ gdzie $\gamma=1/\sigma$, $\lambda = \exp\{-[\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k]\}$
- Funkcja hazardu:
 - $\sigma < 1$ najpierw rosnący a potem maleje,
 - $\sigma > 1$ od nieskończoności maleje do 0,
 - $\sigma = 1$ od wartości λ maleje do 0.



Przykład 4. *recidivism data* D=LLOGISTIC

- KOD 1 – z opcją DISTRIBUTION=LLOGISTIC
- Funkcja hazardu ma odwrócony kształt litery U ponieważ Scale (oszacowanie σ) wynosi 0.6471 czyli <1 .

Model gamma (D=GAMMA)

- Najwięcej parametrów, największe uogólnienie. Modele: wykładniczy, Weibulla, log-normalny są szczególnymi przypadkami modelu gamma.
- Skomplikowana formuła funkcji hazardu.
- Czasochłonna procedura estymacji (duże zbiory).
- $$h(t) = \frac{\lambda(\lambda)^{k-1} \exp(-\lambda t) \Gamma(k)^{-1}}{1 - I_k(\lambda t)}$$
 gdzie $\lambda, k > 0$,
$$I_k(s) = \frac{\int_0^s x^{k-1} e^{-x} dx}{\Gamma(k)}$$

Przykład 5. *recidivism data* D=GAMMA

- KOD 1 – z opcją DISTRIBUTION=GAMMA
- Parametr Scale= σ , natomiast nowy parametr Shape= δ .
- Shape=0 – model log-normal,
- Shape=1,0 – model Weibulla (tak jak w tym przykładzie Shape=0.9943 czyli blisko rozkładu Weibulla)

Weryfikacja modelu parametrycznego

- Istotność zmiennych w modelu – test Walda
- Testy typu CONTRAST (porównanie dwóch różnych współczynników przy zmiennych)
- Jakość dopasowania goodness-of-fit test, statystyka LR, metody graficzne

Test Walda

- Dla jednej zmiennej:
- $Wald = \left(\frac{\beta_k}{s(\beta_k)} \right)^2$ rozkład chi-kwadrat z 1 st-swobody.
- Dla wszystkich zmiennych (H_0 zakłada że wszystkie zmienne są nieistotne):
- Likelihood ratio statistics: $LR = -2\log LL$
- Dla dwóch zmiennych (współczynników):
- Wald statistics:
$$\frac{(\hat{\beta}_3 - \hat{\beta}_4)^2}{Var(\hat{\beta}_3) + Var(\hat{\beta}_4) - 2Cov(\hat{\beta}_3, \hat{\beta}_4)}$$

Przykład 6. *recidivism data* CLASS

- KOD 2 – opcja CLASS, nowa zmienna EDUC. Kategoria odniesienia EDUC=5 (opcja COVB).
- Test Walda dla dwóch parametrów należy wyznaczyć ręcznie, dla EDUC=3 i EDUC=4:
 - $\frac{[-0.5116 - (-0.3536)]^2}{0.09549 + 0.1051 - 2(0.08666)} = 0.9154$
- dla 1 st. swob chi-kwadrat wynosi 3,84 więc brak podstaw do odrzucenia hipotezy o równości.

Goodness-of-Fit Test z LR statystyką

- Ocena dopasowania funkcji hazardu.
- Modele zagnieżdżone (*nested*) czyli sytuacja kiedy jeden z modeli jest szczególnym przypadkiem innego modelu poprzez narzucenie ograniczeń na parametry modelu:
 - Model wykładniczy jest modelem Weibulla z parametrem skali wynoszącym 1.
 - Model wykładniczy jest szczególnym przypadkiem modelu gamma dla parametru kształtu *shape* i parametru skali *scale* wynoszącym 1.
 - Model Weibulla ($\text{shape}=1$) i model log-normalny ($\text{shape}=0$) są szczególnymi przypadkami uogólnionego modelu gamma.

Przykład.

- H_0 : ograniczenie na parametrach jest prawdziwe.
- H_1 : ograniczenie na parametrach jest niewłaściwe.
- Test LR: $-2(LL_A - LL_B)$,
- Chi-kwadrat z liczbą stopni swobody równą liczbie ograniczeń na parametrach.
 - 325,83 wykładniczy,
 - 319,38 Weibulla,
 - 322,69 log-normalny,
 - 319,40 log-logistyczny (nie jest zagnieżdżony)
 - 319,38 uogólniony gamma.

Który z modeli jest właściwym do oceny *recidivism data*?

Metody graficzne oceny dopasowania

- PLOTS=LS (PROC LIFETEST) – prosta z punktu 0 – model wykładniczy.
- PLOTS=LLS (PROC LIFETEST) – prosta – model Weibulla.

(nie ocenia dopasowania innych rozkładów, nie uwzględnia zmiennych)

- PROBLOT (PROC LIFEREG) – funkcja przeżycia K-M ze zmiennymi.
Prosta na wykresie reprezentuje transformację funkcji przeżycia oszacowanej przez model i przedział ufności, natomiast punkty empiryczne obrazują faktyczne oszacowania nieparametryczne funkcji przeżycia (powinny leżeć w obszarze CL).

(dla wszystkich rozkładów, uwzględnia zmienne)

Przykład 7.

- KOD 3. PROBPLOT – należy zastosować dla wszystkich wcześniej oszacowanych modeli w KOD 1.
- Model Weibulla spełnia warunek dopasowania.

Obciążenie lewostronne i przedziałowe

- Zdarzenie jest obserwowane w przedziale od a do b , stąd:
 - Obciążenie lewostronne $a=0$, więc $S_i(a)=1$,
 - Obciążenie prawostronne $b=\infty$, więc $S_i(b)=0$,
 - Prawdopodobieństwo zdarzenia wynosi $S_i(a)-S_i(b)$.
- Nie można porównywać LL modeli z prawostronnym i lewostronnym lub przedziałowym obciążeniem.

Przykład 8. *recidivism data* MODEL (lower, upper)

- KOD 4. Obcięcie lewostronne. Modyfikacja danych WEEK=. Dla 30 pierwszych aresztantów.
- KOD 5. Obcięcie przedziałowe. Założenie że zdarzenie wystąpiło w trakcie tygodnia więc obcięcie przedziałowe początek-koniec tygodnia.
- MODEL (lower, upper)=list of variables
 - Pełna obserwacja LOWER, UPPER, obydwie opcje dostępne i równe sobie
 - Obcięcie przedziałowe LOWER, UPPER obecne ale nierówne
 - Obcięcie prawostronne LOWER obecne, UPPER nieobecne
 - Obcięcie lewostronne LOWER nieobecne, UPPER obecne.

Prognozy i funkcja hazardu

- Prognoza czyli oszacowanie oczekiwanego czasu dla każdej jednostki – mediana czasu lub percentyle, błąd standardowy mediany (opcja P, QUANTILES, STD).
- Ostrożnie z interpretacją! Obserwacje obcięte.

Przykład 9. recidivism data (czas, hazard)

- KOD 6. Wydruk oszacowań mediany czasu dla każdej obserwacji.

Model wykładniczy przedziałami stały

- *Piecewise Exponential Model*. Model, dopuszczający hazard zmienny w czasie, ale odcinkami stały.
- Podejście elastyczne, umożliwiające włączenie zmiennych zależnych od czasu.
- Mamy J odcinków czasu z punktami odcięcia $a_0, a_1, \dots, a_J$ gdzie $a_0=0$ oraz $a_J=\infty$, czyli odcinek czasu j wynosi $[a_{j-1}, a_j)$.
- Hazard dla jednostki i ma formę:
- $h_i(t) = \lambda_j e^{\beta \mathbf{x}_i}$ dla $a_{j-1} \leq t < a_j$ lub $\log h_i(t) = \alpha_j + \beta \mathbf{x}_i$ ($\alpha_j = \log \lambda_j$)
- Podział na odcinki czasu arbitralny.

Model wykładniczy przedziałami stały – uwagi

- Wyniki statystyk testowych nie zależą od przyjętej liczby przedziałów czasu.
- Podobny do modelu dla czasu dyskretnego, ale wykorzystuje dokładny czas wystąpienia zdarzenia.
- Nie ma wymagania równej rozpiętości przyjętych odcinków czasu.
- Włączenie zmiennych zależnych od czasu wymaga skomplikowanego przygotowania danych.

Przykład 10. recidivism data (CLASS j)

- KOD 7. CLASS= J podział na odcinki czasu. Podział 52 tygodniowego odcinka czasu na 13 tygodniowe kwartyle. Jeden rekord dla jednego odcinka czasu. Długość odcinka zależy od wystąpienia zdarzenia, inaczej jest 13 tyg. i jest to obserwacja obcięta.
- Zmienne stałe są replikowane dla każdego rekordu.
- Zmienne zależne od czasu mogą zmieniać wartość pomiędzy utworzonymi odcinkami czasu.
- Istotność zmiennej J wskazuje na niestały w czasie wskaźnik hazardu.