

Analiza czasu trwania – modele semiparametryczne

Aneta Ptak-Chmielewska

aptak@sgh.waw.pl

Modele proporcjonalnych hazardów - Coxa

- *Cox regression* – nie zakłada żadnego określonego rozkładu prawdopodobieństwa a tym samym rozkładu czasu przeżycia.
- Włącza zmienne zależne od czasu, czyli zmienne których wartość zmienia się w trakcie trwania obserwacji.
- Dopuszcza analizy warstwowe, które kontrolują zmienne zakłócające.
- Ma zastosowanie zarówno dla ciągłego jak i dyskretnego czasu.
- PROC PHREG (Proportional Hazards Regression)
- *Maximum Partial Likelihood* (Metoda Częściowej Największej Wiarygodności).

Model proporcjonalnych hazardów – zapis

$$h_i(t) = \lambda_0(t) \exp(\beta_1 x_{i1} + \dots + \beta_k x_{ik})$$

lub

$$\log h_i(t) = \alpha(t) + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$

gdzie:

$$\alpha(t) = \log \lambda_0(t)$$

jeżeli:

- $\alpha(t) = \alpha$ – model wykładniczy,
- $\alpha(t) = \alpha t$ – model Gompertza
- $\alpha(t) = \alpha \log t$ – model Weibulla


- i – jednostka, t - moment czasu,
- $\lambda_0(t)$ określona lewostronnie funkcja hazardu bazowego (wartość funkcji hazardu przy wszystkich zmiennych = 0)
- k – liczba zmiennych objaśniających,

Założenie proporcjonalności

Hazard dowolnej jednostki (i) jest w stałej proporcji do hazardu innej jednostki (j), przez cały czas trwania czyli:

$$\frac{h_i}{h_j} = \exp\{\beta_1(x_{i1} - x_{j1}) + \dots + \beta_k(x_{ik} - x_{jk})\}$$

Funkcje hazardu są więc równoległe:



Metoda częściowej wiarygodności

Funkcja wiarygodności może być podzielona na dwie części:

- Część zależną od hazardu bazowego $\lambda_0(t)$ oraz wektora współczynników:
 $\boldsymbol{\beta} = [\beta_1 \beta_2 \dots \beta_k]'$
- Część zależną tylko od współczynników $\boldsymbol{\beta}$.

Funkcja *częściowej* wiarygodności pomija pierwszą część a drugą traktuje tak jakby to była funkcja wiarygodności.

Estymatory nie są w pełni efektywne, błędy standardowe są większe niż w MNW ale są odporne na kształt funkcji hazardu.

Pozostałe własności estymatorów są zachowane.

Nie zależy od wartości czasów trwania ale od ich kolejności, więc wszelkie monotoniczne przekształcenia czasu procesu nie zmieniają oszacowań.

Metoda częściowej wiarygodności – formuły

- Funkcja częściowej wiarygodności:

$PL = \prod_{j=1}^J L_j$ - iloczyn wiarygodności dla obserwacji ze zdarzeniem.

- Funkcja częściowej wiarygodności w modelu proporcjonalnych hazardów ze zmiennymi (niezależnymi od czasu):

$$PL = \prod_{i=1}^n \left(\frac{e^{\beta \mathbf{x}_i}}{\sum_{j=1}^n Y_{ij} e^{\beta \mathbf{x}_j}} \right)^{\delta_i}$$

- Logarytm funkcji częściowej wiarygodności – wygodniejszy do maksymalizacji:

$$\log PL = \sum_{i=1}^n \delta_i [\beta \mathbf{x}_i - \log \sum_{j=1}^n Y_{ij} e^{\beta \mathbf{x}_j}].$$

- Algorytm Newtona-Raphsona.

- n niezależnych jednostek $i=1, \dots, n$
- t_i – czas zdarzenia lub obciążenia,
- δ_i – znacznik obciążenia (0-obciążenie, 1-zdarzenie),
- $\mathbf{x}_i = [x_{i1} \dots x_{ik}]$ – wektor zmiennych.
- J – liczba zdarzeń (nieobciążonych).

- gdzie $Y_{ij}=1$ jeśli $t_j \geq t_i$ oraz $Y_{ij}=0$ jeśli $t_j < t_i$, czyli wykluczenia z mianownika tych jednostek, które już doświadczyły zdarzenia i nie są wystawione na ryzyko.
- PL nie uwzględnia zdarzeń o czasie powiązanym ale dopuszcza zdarzenia i obciążenie w tym samym czasie.

Przykład 1. PROC PHREG

- KOD 1. *Recidivism data*. W modelu semiparametrycznym nie ma wyrazu wolnego, wyraz wolny jest zawarty w hazardzie bazowym.
- HR – hazard ratio.
- Dla binarnych: FIN 0,685 oznacza że hazard aresztowania dla otrzymujących pomoc finansową (1) jest o 31,5% niższy od hazardu dla tych którzy nie otrzymują pomocy (0).
- Dla ciągłych: AGE 0,944 oznacza wzrost wieku o 1 rok zmniejsza hazard aresztowania o 5,6%.

Przykład 2. stan (transplant data)

- KOD 2. Wczytanie zbioru danych z pliku tekstowego. Daty zostały zamienione na dni od 1.01.1960.
 - SURV1 – dni od zaakceptowania do przeszczepu (DOA) do zgonu (DLS).
 - SURV2 – dni od transplantacji (DOT) do zgonu.
 - AGEACCEPT – wiek w momencie akceptacji do przeszczepu.
 - AGETRNS – wiek w momencie transplantacji.
 - WAIT – dni od akceptacji do transplantacji.
 - TRANS – binarna 1- transplantacja, 0-brak – zmienna zależna od czasu.
 - DEAD – binarna 1- zgon w dacie DLS, 0-inaczej (obcięcie).
 - SURG – binarna 1- jeśli był operowany na otwartym sercu przed DOA, 0- inaczej.
 - M1 – liczba dawców niepasujących; M2 – kod 1 jeśli dopasowany dawca, 0-inaczej, M3 – punktacja dopasowania.
- KOD 2. PHREG – wyniki mylące ze względu na nie uwzględnienie zmiennych zależnych od czasu i obciążenia lewostronnego.

Obserwacje o czasie powiązanym TIED DATA

- Domyślny algorytm *Breslowa* sprawdza się tylko dla nielicznych zdarzeń o czasie powiązanym (*ties*).
- Inne opcje: algorytm *Efrona*, metody dokładne (*exact*).
- TIES=EXACT – metoda dokładna, zakłada że występuje kolejność zdarzeń ale ze względu na niedokładność pomiaru są one zapisane pod tym samym czasem (czyli czas jest ciągły).
- TIES=DISCRETE – metoda dyskretna, zakłada że zdarzenia faktycznie wystąpiły w dokładnie tym samym czasie (momencie czasu).

Metoda EXACT

- Dla czasów powiązanych rozpatrujemy wszystkie możliwe kombinacje kolejności wystąpień i wyznaczamy prawdopodobieństwo jako iloczyn prawdopodobieństw.
- Np. przy 5 obserwacjach o czasie powiązanym mamy $5!=120$ przypadków.
- Zajmuje dużo czasu do przeliczenia przy dużej liczbie przypadków o czasie powiązanym.
- Stąd przybliżenie np. *Breslowa* (domyślne w PHREG) lub np. *Efrona*.
- Przybliżenie może być niezadowalające w przypadku gdy liczba zdarzeń o czasie powiązanym dla danego punktu w czasie jest znacząco wyższa niż liczba jednostek wystawionych na ryzyko w tym punkcie czasu.

Metoda DISCRETE

- Założenie czasu dyskretnego nie w pełni jest zbieżne z modelem PH Coxa. t - czas przyjmuje tylko wartości całkowite.
- P_{it} – warunkowe prawdopodobieństwo wystąpienia zdarzenia w czasie t pod warunkiem że nie wystąpiło dotychczas. Stąd model określamy jako model proporcjonalnych *odds*:
- $$\log\left(\frac{P_{it}}{1-P_{it}}\right) = \alpha_t + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$
- Lewa strona to tzw. logit lub log-odds a prawa to liniowa funkcja zmiennych oraz zestaw stałych α_t .
- Proporcjonalność zakłada że proporcja *odds* dla dwóch jednostek jest niezależna od czasu.
- Model może być oszacowany z wykorzystaniem MLE lub PLE (zakładając α_t -y jako parametry zakłócające i szacując tylko β -ty).

Przykład 3. *recidivism data* TIES

- KOD3 z opcją EXACT a następnie opcją EFRON (aproksymacja) i dla porównania opcją DISCRETE.
- Przy małej liczbie zdarzeń różnice są na kolejnym miejscu po przecinku.
- Przy czasie dyskretnym różnice są znaczne dla oszacowań współczynników ponieważ to jest zamiast proporcjonalnych hazardów – model proporcjonalnych *odds*.

Zmienne zależne od czasu

- $\log h_i(t) = \alpha(t) + \beta_1 x_{i1} + \beta_2 x_{i2}(t)$
- czyli hazard zależy od x_1 oraz od x_2 w czasie t .
- Zmienna $x_2(t)$ zależna od czasu może być zdefiniowana na różne sposoby (opóźnienie, skumulowanie, itd.).
- Sposób dostosowania danych (ten sam wynik):
 - *Programming statements* – jeden rekord danych dla jednostki a zmienna zależna od czasu zakodowana jako kilka zmiennych w tym rekordzie danych.
 - *Counting process* – kilka rekordów dla jednej jednostki, w każdym z odcinków zmienna zależna od czasu ma stałą wartość.

Przykład 4. *heart transplant data*

- KOD 4. Programming statement. Zmienna zależna od czasu PLANT: 1-transplanatacja w dniu t , 0-brak transplantacji.
- IF porównuje czas oczekiwania dla pacjentów którzy byli wystawieni na ryzyko zgonu z czasem przeżycia dla pacjentów, którzy doświadczyli zdarzenia, czyli SURV1 w tym wyrażeniu nie jest czasem przeżycia danego pacjenta ale czasem przeżycia innego pacjenta, który zmarł.
- Wynik: transplantacja nie ma wpływu na ryzyko zgonu.
- KOD 5. Counting process. Podział epizodu na odcinki w których zmienna zależna od czasu jest stała, czyli dla osób które miały transplantację będzie dwa odcinki (dla PLANT=0, obcięty oraz PLANT=1, obcięty lub zgon) a dla osób które nie miały tylko jeden odcinek. Razem 172 rekordy (34 pojedyncze i 69 podwójne).

Zmienne z alternatywnym czasem początku

- np. aktualny wiek lub czas kalendarzowy.
- $\log h(t) = \alpha(t) + \beta_1 x_1 + \beta_2 x_2(t) + \beta_3 x_3(t)$ oraz $x_3(t) = x_3(0) + t$
- gdzie np. $x_3(t)$ - aktualny wiek, natomiast $x_3(0)$ - wiek w momencie startu.
- stąd:
- $\log h(t) = \alpha^*(t) + \beta_1 x_1 + \beta_2 x_2(t) + \beta_3 x_3(0)$, $\alpha^*(t) = \alpha(t) + \beta_3 t$
- czyli model ze zmienną wiek niezależną od czasu zamiast zmiennej wiek zależnej od czasu.
- W przypadku nieliniowej zależności $\log h(t)$ od czasu startu otrzymujemy model ze zmienną zależną od czasu:
- $\log h(t) = \alpha(t) + \beta_1 x_1 + \beta_2 x_2(t) + \beta_3 \log x_3(t)$

Przykład 5. *heart transplant data*

- KOD 6 – zmienna wiek aktualny, czyli wiek w momencie akceptacji do programu (start) plus czas do zdarzenia. Model ze zmienną wiek aktualny sprowadzoną do postaci zmiennej niezależnej od czasu.
- KOD 7 – zmienna wiek aktualny nieliniowo zależna od hazardu czyli model ze zmienną zależną od czasu.

Zmienne zależne od czasu mierzone w regularnych przedziałach

- Np. regularne badania co miesiąc w programie danej choroby dają informację o stanie (zmiennej) na początek każdego miesiąca.
- Można uwzględnić informację o stanie z opóźnieniem z poprzedniego okresu/odcinka (lub sprzed kilku okresów) dla zachowania zależności przyczynowo-skutkowej (lag).
- Można uwzględnić skumulowaną wartość zmiennej do początku okresu (odcinka) w którym wystąpiło zdarzenie.
- Można ewentualnie odcinki czasu uzależnić od zmiany w zmiennej zależnej od czasu, bez wpływu na wynik.

Przykład 6. *recidivism data*

- KOD 8 – zmiana z formatu emp1-emp52 na format EMPLOYED czyli znacznik wystąpienia zatrudnienia dla wszystkich, którzy są wystawieni na ryzyko zdarzenia. Nie uwzględnia (lag) czyli zależność przyczynowo skutkowa może być nie zachowana, w tym samym tygodniu aresztowanie i zatrudnienie.
- KOD 9 – dodanie opóźnienia, lag, czyli zatrudnienie w tygodniu poprzedzającym aresztowanie, dla zachowania przyczynowo-skutkowego charakteru.
- KOD 10 – opóźnienie o dwa okresy. Skorelowanie pomiędzy lag1 i lag2.
- KOD 11 – skumulowana historia zatrudnienia przed tygodniem aresztowania, czyli przez ile tygodni był zatrudniony.
- KOD 12 – powtórzenie analizy z wykorzystaniem metody *counting process*.

Ad-Hoc oszacowanie zmiennych zależnych od czasu

- W sytuacji kiedy pomiar czasu zdarzenia jest odmienny od pomiaru czasu zmiennej objaśniającej.
- Przybliżamy, imputujemy wartości poprzez wartości najbliższe do momentu wystąpienia zdarzenia.
- Np. mamy pomiar krwi na początku każdego miesiąca a data zgonu jest dana z dokładnością do dnia. Przyjmujemy wartość pomiaru krwi z początku miesiąc w którym wystąpił zgon.

Przykład 7. *blood data*

- KOD 13 – pomiar miesięczny zmiennej objaśniającej zależnej od czasu i pomiar dzienny zmiennej zależnej (zgon) – *programming statement*.
- KOD 14 – wykorzystanie *counting process*.
- KOD 15 – wykorzystanie trendu z ostatnich dwóch miesięcy – *programming statement*.
- KOD 16 – i z wykorzystaniem *counting process*.
- Uwaga! Wykorzystujemy tylko dane przed zdarzeniem (zgon) nawet jeśli są dostępne dane po zdarzeniu (np. jeśli to było obcięcie).

Zmienne zależne od czasu zmieniające się w nieregularnych przedziałach

- Zmiana w zmiennej zależnej od czasu może wystąpić w dowolnym czasie, nieregularnie i może występować wielokrotnie.

Przykład 8. *alcoholic cirrhosis*

- KOD 17 – zależność zgonu od PT najbliższego pomiaru do zgonu – *programming statement*. Brak wpływu. Wpływ jest dopiero jak zmierzymy zmianę PT od początkowego pomiaru do najbliższego do zgonu.
- PT1-PT10 – czas krzepnięcia krwi, mierzony podczas wizyty,
- TIME2-TIME10 – czas w miesiącach od diagnozy do kolejnej wizyty,
- DEAD – 1 zgon, 0 obcięcie
- KOD 18 – i z wykorzystaniem *counting process*.

Model Coxa nieproporcjonalnych hazardów – weryfikacja założenia proporcjonalności

- Naruszenie założenia proporcjonalności hazardów jest równoznaczne z interakcją zmiennej/zmiennych z czasem.
- Weryfikacja założenia proporcjonalności za pomocą reszt w modelu:
 - reszty martyngałowe (opcja ASSESS) – weryfikacja graficzna, *empirical score process* obserwowany w porównaniu do symulacji dla zmiennych (20 prób) w przypadku rozbieżności założenie PH nie jest spełnione. Można poprzeć to p-value z 1000 symulacji opcją RESAMPLE.
 - reszty Schoenfelda (opcja RESSCH, i korelacje) – wartość faktyczna zmiennej dla jednostki minus wartość oczekiwana tej zmiennej dla jednostki (bez obciętych). Przy spełnionym założeniu PH reszty powinny być niezależne od czasu.
- Dwie metody rozszerzenia modelu do nieproporcjonalnych hazardów:
 - Interakcje z czasem jako zmienne zależne od czasu
 - Modele warstwowe – *stratification*.

Przykład 9. *recidivism data* ASSESS

- KOD 19. reszty martygałowe - opcja ASSESS (bez zmiennych zależnych od czasu) w wersji graficznej i opcja RESAMPLE pokazująca p-value testu typu K-S na 1000 symulacjach.
- Zmienna AGE nie spełnia założenia PH, p-value <0.05.
- KOD 20. reszty Schoenfelda – również dla zmiennych zależnych od czasu ale tylko w opcji *counting process*. Reszty są generowane dla każdej zmiennej dla każdej obserwacji (bez obciętych).
- PROC CORR – sprawdzamy korelację z czasem, z logarytmem czasu, kwadratem itd.
- Zmienna AGE nie spełnia założenia PH, ewentualnie na granicy WEXP.

Interakcja z czasem jako zmienne zależne od czasu

- $\log h(t) = \alpha(t) + \beta_1 x + \beta_2 xt$ lub $\log h(t) = \alpha(t) + (\beta_1 + \beta_2 t)x$
- β_2 - „+” oznacza rosnący w czasie efekt wpływu zmiennej x
- β_2 - „-” oznacza malejący w czasie efekt wpływu zmiennej x
- β_1 - oznacza efekt wpływu zmiennej x w czasie 0 (start).

Przykład 10. *recidivism data* ($t \times x$)

- KOD 21 – włączenie zmiennej zależnej od czasu $z=xt$ z wykorzystaniem *programming statement*.
- AGE – efekt dla WEEK=0 czyli w momencie zwolnienia z aresztu oznacza że każdy kolejny rok AGE zwiększa ryzyko aresztowania o 3,8% (HR=1,038).
- AGEWEEK – efekt interakcji z czasem, można wyznaczyć efekt dla dowolnego tygodnia poprzez obliczenie $0,03692 - 0,00369 \times \text{WEEK}$. Np. dla 10 tygodnia wynosi ok 0, dla 20 tygodnia -0,0369, dla 30 tygodnia -0,0738, dla 40 tygodnia -0,1107.
- TEST – sprawdzenie dla dowolnego tygodnia czy ten efekt faktycznie różni się od 0.

Nieproporcjonalne hazardy i Warstwowanie

- Głównie dla zmiennych dyskretnych i nie bezpośrednio wpływających.
- $\log h_i(t) = \alpha_z(t) + \beta x_i$
- Estymacja z wykorzystaniem metody częściowej wiarygodności:
 - Konstrukcja oddzielnie funkcji wiarygodności dla każdej grupy,
 - Mnożenie tych funkcji przez siebie,
 - Oszacowanie parametrów jako wynik maksymalizacji tej funkcji.
- Wady modeli warstwowych:
 - Brak oszacowania wpływu zmiennej wykorzystanej do warstwowania,
 - Nie ma możliwości testowania bezpośredniego wpływu tej zmiennej, ani w interakcji,
 - Włączenie bezpośrednich interakcji daje lepsze oszacowania innych zmiennych.

Przykład 11. *recidivism data* STRATA

- KOD 22 – opcja STRATA model warstwowy. Nie pokazuje oszacowania dla zmiennej warstwowej, jest to zawarte w funkcji czasu. Nie można zmiennej STRATA włączyć do modelu.
- Uwaga przy zbyt dużej liczbie kategorii!!!
- Zmienna warstwowa powinna być raczej zewnętrzną typu *cluster*.

Obcięcie lewostronne i późne wejście

- Częściowe/czasowe usunięcie z wystawienia na ryzyko zdarzenia.
- Np. badanie czasu przeżycia pacjenta od diagnozy. Pacjent jest rekrutowany do programu w różnym czasie po diagnozie, nie będzie więc obserwowany jeśli zgon nastąpi po diagnozie ale przed rekrutacją do programu.
- Rozwiązaniem jest usunięcie ze zbioru jednostek wystawionych na ryzyko tych jednostek dla których zdarzenie nastąpiło przed kontaktem.
- Przypadek czasowego usunięcia z wystawienia na ryzyko – konstrukcja nowego jednolitego odcinka czasu bez tej przerwy.

Przykład 12. *Heart Transplant Data*

- KOD 23 – modyfikacja modelu gdzie hazard jest określony względem wieku a nie akceptacji do programu (counting process).
- KOD 24 – *programming statement* do włączenia zmiennych zależnych od czasu PLANT.
- Widoczny jest istotny wpływ zmiennej AGEACCPT czyli wiek w momencie akceptacji do programu. W modelu ze zmienną czas od akceptacji ten efekt wieku był zawarty w hazardzie bazowym.
- Przykład. Konstrukcja nowych odcinków czasu dla jednostek będących poza obserwacją przez jakiś czas (split). Pierwszy odcinek jest obcięty a drugi obcięty lub zakończony zdarzeniem.
- `MODEL (start, finish)*CENSOR(0)=X1 X2;`

Oszacowanie funkcji przeżycia

- Dla modelu bez zmiennych zależnych od czasu:
- $S_i(t) = [S_0(t)]^{\exp(\beta \mathbf{x}_i)}$
- $S_0(t)$ – bazowa funkcja przeżycia (czyli dla wszystkich zmiennych wynoszących 0)
- Może być oszacowany za pomocą nieparametrycznej metody największej wiarygodności.
- Dla zmiennych zależnych od czasu można ewentualnie wykorzystać *counting process*.

Przykład 13. *recidivism data* BASELINE

- KOD 25 – opcja BASELINE wyznacza bazową funkcję przeżycia, opcja PLTS. Funkcja przeżycia jest wyznaczona dla wektora średnich dla zmiennych objaśniających. Lcl i ucl to 95% przedział ufności dla funkcji przeżycia.
- Dla zmiennych nominalnych będzie to raczej jedna z kategorii zamiast średniej.
- KOD 26 – wykorzystanie BASELINE do testowania różnic między funkcjami przeżycia kontrolując wartości pozostałych zmiennych (OVERLAY – do pokazania więcej niż jednej funkcji na tym samym wykresie).
- KOD 27 – wykorzystanie BASELINE do wyznaczenia funkcji przeżycia dla konkretnych wartości zmiennych objaśniających.

Weryfikacja modeli semiparametrycznych

- W podejściu klasycznym do oceny **istotności** oszacowań poszczególnych **parametrów** semiparametrycznego modelu Coxa stosuje się modyfikacje statystyk stosowanych w przypadku modeli szacowanych metodą największej wiarygodności.
 - Test ilorazu wiarygodności
 - Test Walda
 - Test punktowy
- Do weryfikacji hipotez w większości przypadków można używać zamiennie CONTRAST i TEST.
- Można testować tyle warunków ile się chce.

Weryfikacja modeli semiparametrycznych

- Modyfikacja **kryteriów informacyjnych** na potrzeby analizy przeżycia polega na uwzględnieniu podziału wszystkich obserwacji ze względu na cenzurowanie i na uwzględnieniu liczby zdarzeń zamiast liczby obserwacji przy wyznaczaniu statystyk AIC lub BIC.
- Dla semiparametrycznego modelu Coxa odpowiednikiem powszechnie stosowanego dla modeli parametrycznych kryterium R-kwadrat jest kryterium:

$$R_p^2 = 1 - \left\{ \exp \left[\frac{2}{n} \left(\ln \left(L_P(\hat{\beta}; \mathbf{t}, \mathbf{v}) \right) - \ln(L_P(0; \mathbf{t}, \mathbf{v})) \right) \right] \right\},$$

gdzie

$L_P(\hat{\beta}; \mathbf{t}, \mathbf{v})$ - wartość funkcji częściowej wiarygodności dla modelu ze zmiennymi objaśniającymi,

$L_P(0; \mathbf{t}, \mathbf{v})$ - wartość funkcji częściowej wiarygodności dla modelu tylko z wyrazem wolnym.

Przykład 14. *recidivism data* CONTRAST

- KOD 28 – zmienna educ została potraktowana jako CLASS, czyli 5 różnych kategorii zostało zakodowanych jako 4 zmienne binarne a jedna z nich (ostatnia) jako referencja (ewentualnie można zmienić CLASS educ(REF=„2”)).
- CONTRAST „ed3 vs. ed5” educ 0 1 0 -1; - test hipotezy że współczynniki przy kategorii 3 i 5 są sobie równe. Różnice nie są statystycznie istotne.

Wskaźniki hazardu

- HAZARDRATIO – opcja zmieniająca jednostki odniesienia we wskaźniku hazardu np. z 1 zł na 1000zł.
- HAZARDRATIO – dodatkowo pokazuje HR dla interakcji, dla dowolnych jednostek.

Przykład 15. *recidivism data* HAZARDRATIO

- KOD 29 – zmiana jednostki dla HR z 1 roku do 5 lub 10 lat dla zmiennej AGE.
- Dodatkowo opcja pokazuje HR dla interakcji np. FIN*AGE dla dowolnych jednostek.
- HAZARDRATIO fin/at (age=20 25 30 35 40) CL=PL;
- Np. w wieku 25 lat otrzymanie finansowej pomocy redukuje hazard aresztowania o 44%.

Krzywa ROC zależna od czasu

Krzywa ROC zależna od czasu - ocena dokładności predykcji w określonych momentach w czasie.

Niech T oznacza zmienną opisującą czas do wystąpienia zdarzenia, a $Z_i = \mathbf{x}_i' \boldsymbol{\beta}$ dla i -tej jednostki ($i = 1, 2, \dots, n$).

Niech $D_i(t)$ oznacza status i -tej jednostki w momencie t zdefiniowany w następujący sposób:

$$D_i(t) = I(T \leq t)$$

Wówczas dla danego punktu odcięcia c czułość (Se) i specyficzność (Sp) zależną od czasu można zdefiniować w następujący sposób:

$$Se(c, t) = P(Z_i > c | D_i(t) = 1),$$

$$Sp(c, t) = P(Z_i \leq c | D_i(t) = 0).$$

Krzywa ROC zależna od czasu

Niech TPR (*True Positive Rate*) będzie dane wzorem:

$$TPR(c, t) = Se(c, t),$$

FPR (*False Positive Rate*) wyznaczane jest w następujący sposób:

$$FPR(c, t) = 1 - TNR(c, t) = 1 - Sp(c, t),$$

gdzie TNR oznacza *True Negative Rate*.

Przy przyjętych oznaczeniach dla **dowolnego momentu t** i **różnych punktów odcięcia c** krzywą ROC zależną od czasu (*time-dependent ROC curves*) można zdefiniować wzorem:

$$ROC(t) = \{(FPR(c, t), TPR(c, t)): c \in \mathbf{R}\}.$$

Zależne od czasu pole pod krzywą ROC - AUC (*time-dependent AUC*) jest zdefiniowane w następujący sposób:

$$AUC(t) = \int_{-\infty}^{+\infty} Se(c, t) d[1 - Sp(c, t)].$$

Przykład 16. *recidivism data* ROC

- KOD 30 – krzywa ROC zależna od czasu – ocena dokładności predykcji w określonych momentach czasu.