

Wprowadzenie do analizy czasu trwania

Aneta Ptak-Chmielewska

aptak@sgh.waw.pl

Czym jest analiza czasu trwania – analiza historii zdarzeń?

- *Survival analysis* is a class of statistical methods for studying the occurrence and timing of events (Allison 2010).
Survival data have two common features that are difficult to handle with conventional statistical methods: *censoring* and *time-dependent* covariates (time-varying explanatory variables).
- **Event history analysis** studies *transitions* across a set of discrete states, including the length of *time intervals* between entry and exit from specific states (Blossfeld, Rohwer 2002).

ACT - definicja

- Analiza czasu trwania – zbiór metod służących do analizy danych, w których badaną zmienną jest czas, jaki upływa od początku obserwacji do chwili wystąpienia określonego zdarzenia, zwany czasem trwania.
- W analizie przeżycia przedmiot zainteresowania stanowi grupa jednostek, dla której definiowane jest zdarzenie zachodzące po określonym czasie.
- Czas oczekiwania na wystąpienie tego zdarzenia musi być precyzyjnie zdefiniowany dla każdej badanej jednostki. W tym celu określa się **zdarzenie początkowe**, które definiuje badaną zbiorowość oraz **zdarzenie końcowe**, które eliminuje obserwowaną jednostkę z określonej zbiorowości.

Zastosowania ACT

- Rynek pracy, badania nierówności społecznych
- Analiza demograficzna, zgony
- Analiza rynku przedsiębiorstw
- Medycyna, epidemiologia
- Badanie zawodności maszyn
- Kryminologia, areszty
- Badania psychologiczne
- Event history analysis (socjology)
- Reliability analysis, failure time analysis (engineering)
- Duration analysis, transition analysis (economics)
- Survival analysis (medicine)


Substantive process

Coleman (1981) characterised *substantive process* in the following way:

1. there is a collection of units (which may be individuals, organizations, societies, or whatever), each moving among a finite (usually small) number of states;
2. those changes (or events) may occur at any point in time (i.e., they are not restricted to predetermined points in time); and
3. there are time-constant and/or time-dependent factors influencing the events.

Mechanizm przyczynowości – *causality*

- Przyczynowość a korelacja
- Następstwo w czasie: $\Delta X_t \rightarrow \Delta Y_{t'}$
- Prawdopodobieństwo:
 $\Delta X_t \rightarrow P(\Delta Y_{t'}) \quad t < t'$



Pojęcie cechy

W badaniach statystycznych wyróżniamy dwa zasadnicze typy cech:

- mierzalne (ilościowe),
- cechy niemierzalne (jakościowe).

Wśród cech mierzalnych wyróżniamy cechy:

- ciągłe,
- skokowe.

Pojęcie cechy w ACT

W analizie czasu trwania wyróżniamy dodatkowo podział na cechy stałe i zmienne oraz cechy pierwotne i wtórne.

Cechy stałe to takie cechy, które nie ulegają zmianie w czasie całego życia jednostki (np. płeć biologiczna, miejsce urodzenia, miejsce wyprodukowania danego produktu).

Cechy zmienne to takie cechy, których wartości mogą ulegać zmianom w czasie (np. liczba posiadanych dzieci, liczba zmian pracodawcy, wykształcenie).

Cechy pierwotne to takie cechy, które służą do identyfikacji stanu, w którym znajduje się jednostka (np. bezrobocie, pozostawanie w zatrudnieniu, posiadanie określonego produktu bankowego).

Cechy wtórne to cechy, które różnicują jednostki znajdujące się w tym samym stanie (np. poziom wykształcenia, miejsce zamieszkania, wiek).

Pojęcie zdarzenia i epizodu

Zdarzenie - każda zmiana w wartościach cechy pierwotnej (przejście jednostki z jednego stanu do drugiego).

Zmiany stanów mogą występować w dowolnym momencie – niektóre z nich są odwracalne, a niektóre nie.

Wyróżniamy zdarzenia:

- początkowe (rozpoczynające określony proces),
- powtarzalne (może powtarzać się kilkakrotnie w ciągu życia jednostki),
- niepowtarzalne.

Przedstawiony podział niekoniecznie musi być rozłączny:


- zdarzenie początkowe – urodzenie pierwszego dziecka,
- zdarzenie powtarzalne – urodzenie dziecka,
- zdarzenie niepowtarzalne – urodzenie pierwszego dziecka.

Pojęcie zdarzenia i epizodu

- Epizod – okres między dwoma kolejnymi zdarzeniami, w przypadku pojedynczych epizodów jest to czas między stanem wyjścia a stanem przeznaczenia.
- Kariera – sekwencja zdarzeń danego typu. Początkiem kariery jest wystąpienie zdarzenia inicjującego, po którym następują inne zdarzenia w określonym porządku.
- Kariery można podzielić na: równoległe, następujące po sobie, komplementarne i konkurencyjne.

Podstawowe modele

- Model pojedynczego epizodu (*single episode*)
- Model wielostanowy (w tym: model ryzyk konkurencyjnych) (*multi-state, competing risks*)
- Model wielu epizodów (*multi-episode*)




Censoring (Obcięcie)

- Obcięcie prawostronne (*right censoring*)
- Obcięcie lewostronne (*left censoring*)
- Obcięcie obustronne (*left and right censoring*)

- Obcięcie typu I (*Type I censoring*) – stały czas obcięcia
- Obcięcie typu II (*Type II censoring*) – czas obcięcia zależny od liczby zdarzeń obciętych
- Obcięcie losowe (*random censoring*) – obcięcie niekontrolowane

Noninformative censoring – założenie ACT

- A crucial condition is that, conditionally on the values of any explanatory variables, the prognosis for any individual who has survived to c_i should not be affected if the individual is censored at c_i . That is, an individual who is censored at c should be representative of all those subjects with the same values of the explanatory variables who survived to c (Cox and Oakes 1984).



Obcięcie prawostronne

Informacje o cenzurowaniu wprowadza się do modelu za pomocą zmiennej cenzurującej.

Rozważmy n jednostek. Niech zmienna losowa T_i , $T_i > 0$ oznacza czas do wystąpienia porażki dla i -tej jednostki, $i = 1, \dots, n$ a C_i niech oznacza okres obserwacji, w trakcie którego i -ta jednostka nie doznała porażki.

Dla każdej obserwacji $i = 1, \dots, n$ można zdefiniować zmienną losową t_i w następujący sposób:

$$t_i = \min(T_i, C_i)$$

a zmienną cenzurującą v_i następująco:


$$v_i = \begin{cases} 1, & \text{jeśli } T_i = t_i \\ 0, & \text{jeśli } T_i > t_i \end{cases}$$

dla $i = 1, \dots, n$.


- W pierwszym przypadku w obserwowanym okresie dla danej jednostki zaszło zdarzenie, natomiast w drugim przypadku w badanym okresie zdarzenie nie wystąpiło – taką sytuację określamy mianem **cenzurowania**.

Badania użyteczne w ACT


- Badanie przekrojowe
- Badanie panelowe
- **Badanie wzdluzne**
 - **prospektywne**
 - **retrospektywne**



Badanie przekrojowe
(*cross-sectional*)



Badanie panelowe
(*panel survey*)



Badanie wzdłużne
(*longitudinal*)

Modele i podejścia w ACT

- Modele nieparametryczne
 - Tablice trwania życia tradycyjne
 - Tablice estymowane metodą Kaplana-Meiera
- Modele parametryczne
 - model Gompartz'a
 - model Weibull'a
 - model Log-logistyczny
 - model Log-normalny
- Modele semiparametryczne
 - semiparametryczny model regresji Coxa

Podstawowe funkcje w ACT

- Dystrybuanta (*cumulative distribution function*)
- **Funkcja przeżycia** (*survival function*)
- Funkcja gęstości (*probability density function*)
- **Funkcja hazardu** (*hazard function*)

$$F(t) = P\{T \leq t\}$$

$$S(t) = P\{T > t\} = 1 - F(t)$$

$$\lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{\Delta t} = \frac{dF(t)}{dt} = -\frac{dS(t)}{dt}$$

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t}$$

Zależności między funkcjami

$$S(t) = 1 - F(T)$$

$$h(t) = -\frac{\partial \ln(S(t))}{\partial t}$$

$$H(t) = -\ln(S(t))$$

$$S(t) = \exp(-H(t))$$

Funkcja hazardu, intensywności przejścia

- Although it may be helpful to think of the hazard as the instantaneous probability of an event at time t , it's not really a probability because the hazard can be greater than 1.0. This can happen because of the division by Δt in equation. Although the hazard has no upper bound, it can not be less than 0.
- Because the hazard is defined in terms of probability (which is never directly observed), it is itself an unobserved quantity. We may estimate the hazard with data, but that's only estimate.
- It is most useful to think of the hazard as a characteristic of individuals, not of populations or samples (unless everyone in the population is exactly the same). Each individual may have a hazard function that is completely different from anyone else's.

Pojęcie czasu T w ACT

- Start (*origin*) – zmiana punktu zmienia parametry modelu:
 - Wiek (np. od urodzenia)
 - Czas kalendarzowy (od konkretnej daty)
 - Czas od zajścia zdarzenia (urodzenie1, urodzenie 2, itd.)
 - Czas od zajścia innego zdarzenia (małżeństwo, rozwód)
- Wybór punktu startowego jest kluczowy w AHZ
- Skala pomiaru czasu (lata, miesiące, dni itd.) – zmiana skali nie zmienia parametrów modelu
- Zmienna czas T ciągła lub dyskretna

Struktura danych w ACT

OBS	DUR	STATUS	TREAT	RENAL
1	8	1	1	1
2	180	1	2	0
3	632	1	2	0
4	852	0	1	0
5	52	1	1	1
6	2240	0	2	0
7	220	1	1	0
8	63	1	1	1
9	195	1	2	0
10	76	1	2	0

Myelomatosis Data

OBS – numer obserwacji

DUR – czas życia pacjenta (dni) od wyboru do próby i poddania terapii

STATUS – zgon (1), obcięcie (0)

TREAT – dwa rodzaje terapii

RENAL – funkcjonowanie pacjenta w dniu wyboru do próby (1,0)

*SAS – pomiar czasu (1.01.1960)

Procedury w SAS

- LIFETEST
- LIFEREG
- PHREG
- LOGISTIC
- GENMOD
- NLMIXED